

## TASK.1 - ARMOCROMIA DEI VOLTI

### ABSTRACT

Questo lavoro si propone di definire un classificatore armocromatico a partire dai volti. L'armocromia è una delle tendenze più in voga negli ultimi anni, nonché una vera e propria disciplina che permette di individuare la *palette cromatica* dei cosiddetti “colori amici”, ovvero i colori che valorizzano maggiormente la persona, attraverso l'analisi della combinazione di pelle, occhi e capelli. Il software utilizzato per questo progetto è stato *Orange Data Mining* nella sua versione 3.36.2 tramite l'allenamento sul modello di rete neurale convoluzionale (*CNN*), effettuando una classificazione sulla rete *SqueezeNet*<sup>1</sup>.

Dopo aver analizzato diversi articoli autorevoli nei quali era riportata la classe armocromatica di varie celebrità e scaricato le rispettive immagini, ciascun componente del gruppo ha classificato 300 immagini di un dataset esistente di volti (*Celeb-A*), catalogando ciascuna di esse in base alla rispettiva classe armocromatica e cercando di seguire il più possibile le regole basi dell'armocromia. Dopo la fase di catalogazione, abbiamo caricato le immagini all'interno di *Orange Data Mining* già suddivise in Train e Test set e tramite una *CNN* abbiamo estratto le *Feauters*. Successivamente abbiamo effettuato un *Fine-Tuning FC Layer*, infine sui dati di Test è stata fatta la valutazione. Questo processo è stato condotto seguendo un approccio supervisionato.

Dai risultati, sono emerse diverse *misclassificazioni*, le quali sono state analizzate e discusse.

### INTRODUZIONE

La teoria delle stagioni suddivide gli individui in quattro gruppi: estate, autunno, inverno e primavera. Questa classificazione non riguarda il guardaroba, ma i colori naturali dell'individuo, che richiamano quelli delle rispettive stagioni e a ciascuna di essa corrisponde una palette di colori che si armonizza con i colori naturali dell'individuo. Questi colori possono essere caldi o freddi, brillanti oppure più tenui ed ognuna delle quattro stagioni è caratterizzata dalla misura in cui alcune variabili (sottotono, valore, intensità e contrasto) sono presenti.

Il lavoro è stato suddiviso in più step: inizialmente, sono stati analizzati diversi articoli autorevoli nei quali era definita la

classe armocromatica di varie celebrità e sono state scaricate le rispettive immagini. Sono stati individuati dai 15 ai 25 VIP per ciascuna stagione cromatica e per ciascun VIP sono state scaricate più foto del volto. Successivamente, cercando di seguire il più possibile le regole dell'armocromia, ogni membro del gruppo ha catalogato 300 immagini (per un totale di 900 immagini) che sono state aggiunte alle precedenti immagini scaricate online. Durante la classificazione delle 900 immagini, abbiamo cercato di rispettare il più possibile le regole basilari dell'armocromia. La tabella sottostante riassume le caratteristiche cromatiche di ciascuna classe.

---

<sup>1</sup> SqueezeNet è un modello profondo per il riconoscimento delle immagini che raggiunge un'accuratezza pari a quella di AlexNet su ImageNet con un numero di parametri 50 volte inferiore. Il modello è stato addestrato sul dataset ImageNet.

<b><i>Autunno deep</i></b>  Sottotono pelle caldo (olivastro, beige, marrone), capelli scuri (castano scuro al nero con riflessi caldi), occhi marrone scuro, nocciola o verde scuro.	<b><i>Autunno soft</i></b>  Sottotono pelle caldo (beige, pesca, dorato), capelli dal biondo scuro al castano dorato, occhi verdi, nocciola o marroni.	<b><i>Autunno warm</i></b>  Sottotono pelle caldo (dorato o aranciato), capelli rossi o castano chiaro con riflessi dorati, occhi verdi, nocciola o marroni.
<b><i>Inverno deep</i></b>  Sottotono pelle fredda (chiara, olivastro o scura), capelli molto scuri, occhi marroni, nocciola o verde scuro.	<b><i>Inverno cool</i></b>  Sottotono pelle freddo, capelli scuri senza riflessi caldi, occhi blu, grigi, verdi o marroni scuri.	<b><i>Inverno bright</i></b>  Pelle chiara con sottotono freddo, capelli scuri con riflessi freddi, occhi brillanti e chiari (blu, verde brillante, grigio, nocciola).
<b><i>Estate cool</i></b>  Sottotono pelle freddo, capelli biondi cenere o castano chiaro, occhi blu, grigi, verde chiaro o nocciola.	<b><i>Estate soft</i></b>  Pelle chiara o media con sottotono freddo, capelli biondi scuri o castano medio, occhi grigi, blu-verde, nocciola o marrone chiaro.	<b><i>Estate light</i></b>  Pelle molto chiara con sottotono freddo, capelli biondi chiari o castano chiaro, occhi blu chiaro, verde chiaro o grigio.
<b><i>Primavera bright</i></b>  Sottotono pelle caldo, capelli biondi o castano chiaro con riflessi dorati, occhi brillanti e chiari (blu, verde brillante, nocciola chiara).	<b><i>Primavera light</i></b>  Pelle molto chiara con sottotono caldo, capelli biondi o castano chiaro con riflessi caldi, occhi chiari e luminosi (blu chiaro, verde chiaro, nocciola chiaro).	<b><i>Primavera warm</i></b>  Pelle pesca, dorata o avorio, capelli biondi, rossi o castano chiaro con riflessi caldi, occhi verdi, azzurri o nocciola con toni caldi.

Una volta ottenute tutte le immagini necessarie per ciascuna classe cromatica, le immagini sono state suddivise in 70% Train e 30% Test. Per tenere traccia dell'operato ed evitare errori, è stato redatto un file excel suddiviso in: filepath, classe (autunno deep, autunno warm, autunno soft, inverno deep,

inverno cool, inverno bright, estate light, estate cool, estate soft, primavera bright, primavera light, primavera warm) e partizione (Train, Test).

Dalla fase di catalogazione sono state ottenute 2567 foto in totale (1796 usate per il Train set, 771 usate per il Test set).

A	B	C	D	E	F	G	H	I	J	K	L	M	N
Filepath	Class	Partition											
test\autunno deep\AlessandraAmbrosio3.jpg	autunno deep	test											
test\autunno deep\AlessandraAmbrosio4.jpg	autunno deep	test											
train\autunno deep\AlessandraAmbrosio5.jpg	autunno deep	train											
train\autunno deep\AlessandraAmbrosio6.jpg	autunno deep	train											
train\autunno deep\AlessandraAmbrosio7.jpg	autunno deep	train											
train\autunno deep\AlessandraAmbrosio8.jpg	autunno deep	train											
train\autunno deep\AlessandraAmbrosio9.jpg	autunno deep	train											
train\autunno deep\AlessandraAmbrosio10.jpg	autunno deep	train											
train\autunno deep\AlessandraAmbrosio11.webp	autunno deep	train											
test\autunno deep\AshleyGraham3.jpg	autunno deep	test											
test\autunno deep\AshleyGraham4.jpg	autunno deep	test											
train\autunno deep\AshleyGraham5.jpg	autunno deep	train											
train\autunno deep\AshleyGraham6.jpg	autunno deep	train											
train\autunno deep\AshleyGraham7.jpg	autunno deep	train											
train\autunno deep\AshleyGraham.jpg	autunno deep	train											
train\autunno deep\AshleyGraham1.jpg	autunno deep	train											
train\autunno deep\BelenRodriguez3.webp	autunno deep	train											
test\autunno deep\BelenRodriguez4.jpg	autunno deep	test											
test\autunno deep\BelenRodriguez6.jpg	autunno deep	test											
train\autunno deep\BelenRodriguez7.jpg	autunno deep	train											
train\autunno deep\BelenRodriguez8.jpg	autunno deep	train											
train\autunno deep\BelenRodriguez9.jpg	autunno deep	train											
train\autunno deep\BelenRodriguez5.jpg	autunno deep	train											
train\autunno deep\BelenRodriguez.webp	autunno deep	train											
train\autunno deep\BelenRodriguez1.webp	autunno deep	train											
train\autunno deep\BelenRodriguez10.png	autunno deep	train											
train\autunno deep\BelenRodriguez8.jpg	autunno deep	train											
test\autunno deep\ceciliarodriguez3.jpg	autunno deep	test											
test\autunno deep\ceciliarodriguez4.jpg	autunno deep	test											
train\autunno deep\ceciliarodriguez5.jpg	autunno deep	train											
train\autunno deep\ceciliarodriguez6.webp	autunno deep	train											
train\autunno deep\CeciliaRodriguez.jpg	autunno deep	train											
train\autunno deep\CeciliaRodriguez1.jpg	autunno deep	train											
train\autunno deep\cindy Crawford3.jpg	autunno deep	train											
test\autunno deep\cindy Crawford4.jpg	autunno deep	test											
test\autunno deep\cindy Crawford5.jpg	autunno deep	test											
test\autunno deep\cindy Crawford6.jpg	autunno deep	test											
train\autunno deep\cindy Crawford7.webp	autunno deep	train											
						<b>Immagini autunno deep</b>		<b>Immagini autunno soft</b>		<b>Immagini autunno warm</b>			
						Totale	315		186		159		
						Immagini train set	220	Immagini test set	95	Immagini train set	130	Immagini test set	56
						Immagini train set	220	Immagini test set	95	Immagini train set	130	Immagini test set	56
						Percentuale	0.698412698	0.301587302		0.698924731	0.301075269	0.698113208	0.301886792
						<b>Immagini estate cool</b>		<b>Immagini estate light</b>		<b>Immagini estate soft</b>			
						Totale	173		180		247		
						Immagini train set	121	Immagini test set	52	Immagini train set	126	Immagini test set	54
						Immagini train set	121	Immagini test set	52	Immagini train set	126	Immagini test set	54
						Percentuale	0.699421965	0.300578035		0.7	0.3	0.700404858	0.299595142
						<b>Immagini inverno bright</b>		<b>Immagini inverno cool</b>		<b>Immagini inverno deep</b>			
						Totale	146		217		296		
						Immagini train set	102	Immagini test set	44	Immagini train set	152	Immagini test set	65
						Immagini train set	102	Immagini test set	44	Immagini train set	152	Immagini test set	65
						Percentuale	0.698630137	0.301369863		0.700460829	0.299539171	0.699324324	0.300675676
						<b>Immagini primavera bright</b>		<b>Immagini primavera light</b>		<b>Immagini primavera warm</b>			
						Totale	190		230		228		
						Immagini train set	133	Immagini test set	57	Immagini train set	161	Immagini test set	69
						Immagini train set	133	Immagini test set	57	Immagini train set	161	Immagini test set	69
						Percentuale	0.7	0.3		0.7	0.3	0.701754386	0.298245614

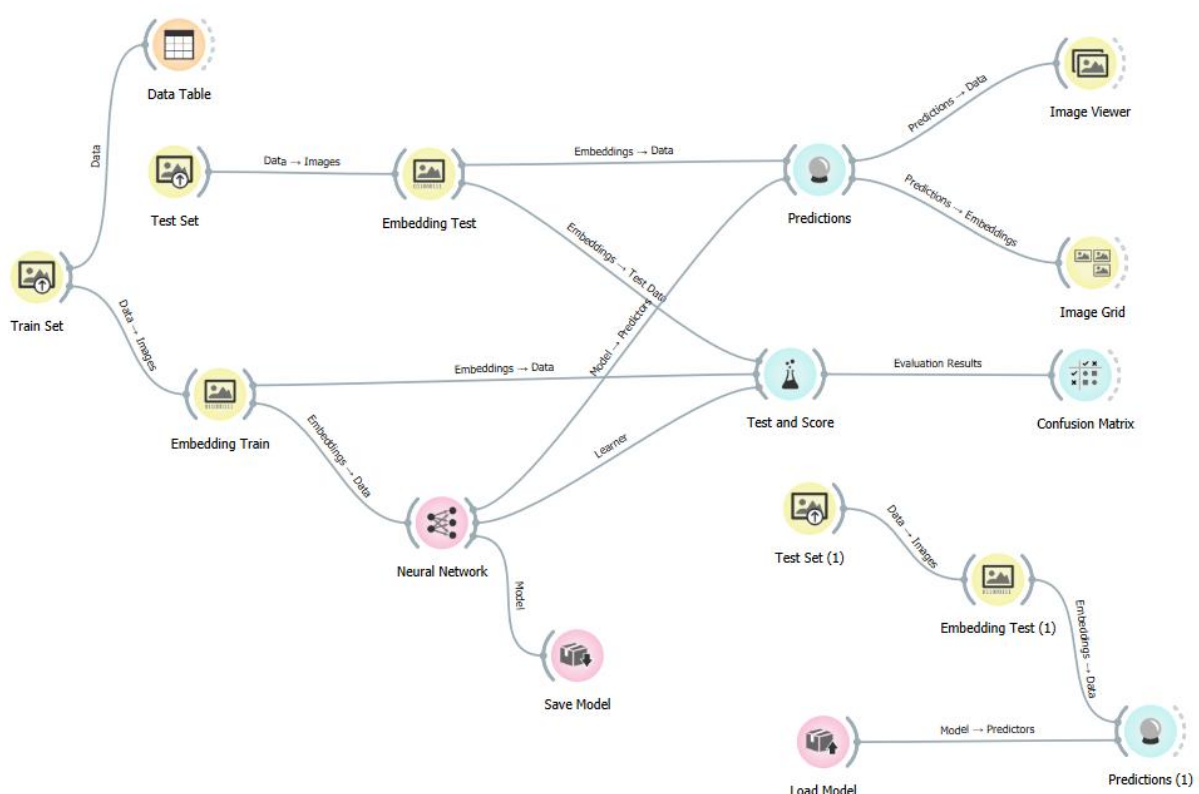
*Import Images* ci ha permesso di importare le cartelle relative al nostro dataset. Il percorso di ciascuna immagine poteva essere visualizzato attraverso il widget *Data Table*. Inizialmente abbiamo importato la cartella Train per addestrare il modello, poi abbiamo duplicato il widget Import Images, ma questa volta abbiamo importato la cartella Test per valutare il modello. In questa maniera abbiamo calcolato le nostre metriche (es. *accuracy*).

*Test and Score* ha consentito di valutare il nostro modello sulla base di Test. Questo widget però, per funzionare ha bisogno di una rete neurale. Infatti, al widget *Test and Score*

*Predictions* ci ha permesso di passare i dati da *Image Embedding* alla *Neural Network* e calcolare le predizioni sul modello appena addestrato. Grazie a questo widget abbiamo potuto vedere tutte le predizioni fatte dal modello per ogni immagine.

Orange fornisce una visualizzazione interattiva, quindi tramite il widget *Image View* abbiamo potuto vedere le immagini dal nostro set di dati e investigare sulle classificazioni errate.

*Save Model* ci ha permesso di salvare il modello appena addestrato.



## MATERIALI E METODI

La ricerca è stata condotta tramite l'utilizzo del software *Orange Data Mining* nella sua versione 3.36.2 e la rete neurale convoluzionale (CNN) selezionata è stata la pre-allenata *SqueezeNet*. Il dataset è stato bilanciato seguendo una suddivisione del 70% per il set di Training e 30% per il set di Testing.

## RISULTATI

Prima di raggiungere una discreta percentuale di accuratezza del nostro modello di classificazione, abbiamo dovuto effettuare diversi tentativi. Nel primo tentativo,

I widget utilizzati sono stati quelli relativi ai gruppi *Image analytics* (Import Images, Images Embedding, Image Viewer, Image Grid), *Model* (Neural Network, Save Model), *Evaluation* (Test and Score, Predictions, Confusion Matrix). Le immagini selezionate sono state scaricate da: Google Immagini e Pinterest. I risultati del task sono stati valutati attraverso la matrice di confusione.

utilizzando le 12 classi inizialmente disponibili, l'accuratezza ottenuta è stata solo del 22,7%, un risultato decisamente insufficiente. Questo potrebbe essere dovuto al fatto che le cartelle Train e Test non erano state adeguatamente bilanciate.

TEST	CA	IMMAGINI	EMBEDDER
autunno deep, autunno soft, autunno warm, inverno deep, inverno bright, inverno cool, estate soft, estate light, estate cool, primavera bright, primavera light, primavera warm	22.7%	771	SqueezeNet

Successivamente, dopo aver riequilibrato ulteriormente le cartelle Train e Test, abbiamo effettuato un secondo tentativo. La percentuale di accuratezza è aumentata di quasi 7 punti percentuali, raggiungendo il 29,2%, ma era ancora insoddisfacente. Come mostrato dalla


matrice di confusione, solo 227 delle 771 immagini del set di test sono state correttamente predette dal modello di classificazione, di conseguenza 554 immagini sono state misclassificate.

		Predicted												Σ
		autunn...	autunn...	autunn...	inverno...	inverno...	inverno...	primav...	primav...	primav...	summe...	summe...	summe...	
Actual	autunn...	37	4	4	3	1	23	0	1	6	6	5	5	95
	autunn...	12	3	1	1	0	10	0	10	4	2	3	10	56
	autunn...	6	0	13	0	1	7	0	7	8	1	1	4	48
	inverno...	17	0	1	7	5	11	0	1	1	0	0	1	44
	inverno...	12	2	3	2	6	17	0	8	2	8	0	5	65
	inverno...	17	1	1	3	9	46	1	4	0	0	2	5	89
	primav...	20	1	1	0	4	11	1	7	4	3	1	4	57
	primav...	4	2	2	0	1	0	0	22	4	3	6	25	69
	primav...	12	2	1	1	3	6	1	11	17	2	3	9	68
	summe...	6	0	2	2	4	9	0	0	0	16	8	5	52
	summe...	0	0	1	0	0	0	0	10	0	3	19	21	54
	summe...	6	1	3	0	5	4	0	12	2	5	2	34	74
Σ		149	16	33	19	39	144	3	93	48	49	50	128	771

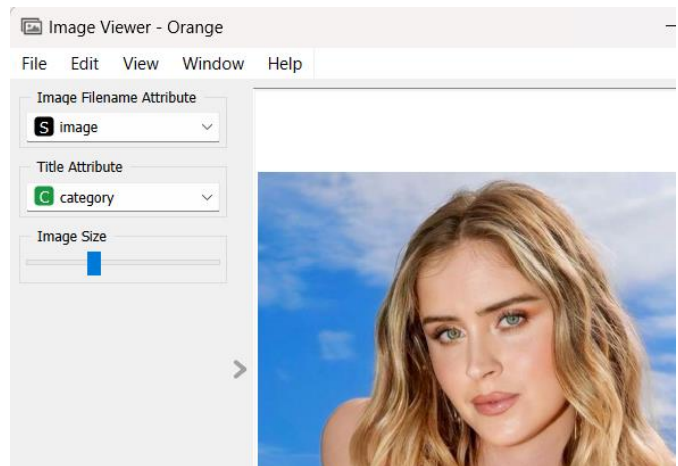
TEST	CA	IMMAGINI	EMBEDDER
autunno deep, autunno soft, autunno warm, inverno deep, inverno bright, inverno cool, estate soft, estate light, estate cool, primavera bright, primavera light, primavera warm	29.2%	771	SqueezeNet

Evaluation results for target (None, show average over classes) ▾						
Model	AUC	CA	F1	Prec	Recall	MCC
Neural Network	0.760	0.292	0.272	0.313	0.292	0.220

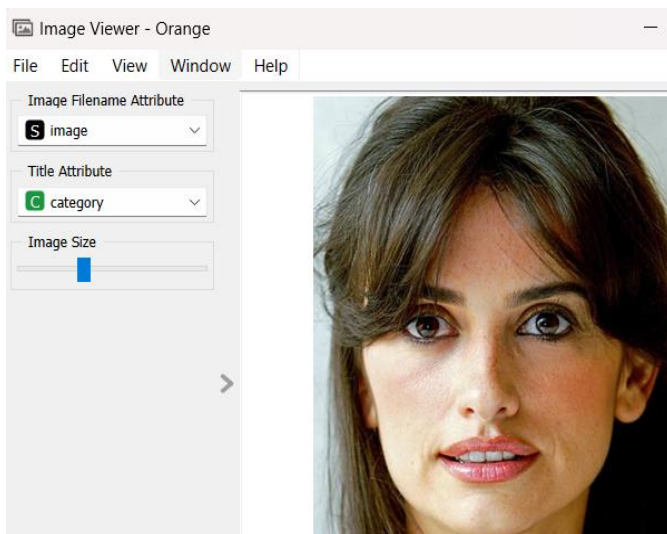
## Esempi di *misclassificazione*



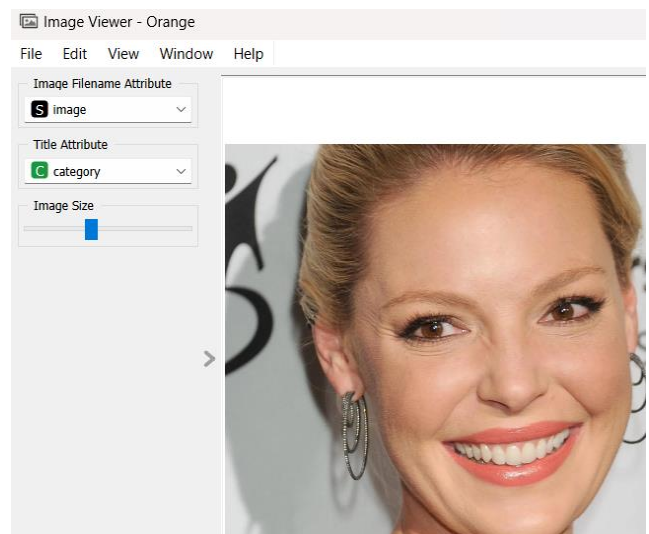
*summer soft* misclassificata in *inverno deep*



*primavera light* misclassificata in *primavera warm*



*inverno deep* misclassificata in *estate soft*



*summer soft* misclassificata in *inverno cool*




Le motivazioni che hanno portato ad una scarsa performance del modello possono essere state le seguenti:

- quantità insufficiente di immagini → pur avendo a disposizione 771 immagini per il Test, la quantità di immagini per ciascuna classe è ancora troppo bassa per permettere al modello di raggiungere buone performance.
- problema di dominio → all'interno della stessa classe c'erano immagini di volti molto diversi tra loro, immagini con caratteristiche visive troppo variabili. Questo potrebbe aver reso difficile identificare pattern coerenti;
- *overfitting* → necessità di diversificare e ridimensionare i dati di addestramento con una rappresentazione completa dei possibili valori e tipi di dati di input;
- incoerenza nell'annotazione → probabilmente l'annotazione potrebbe non essere stata eseguita in modo del tutto coerente, a causa della soggettività del task. In questo caso, il modello potrebbe aver ricevuto segnali confusi durante l'addestramento;

- ambiguità delle classi → alcune classi potrebbero risultare molto simili tra loro, creando ambiguità nel processo di classificazione (es. summer light - primavera light; autunno deep - inverno deep);
- qualità delle immagini → potrebbero esserci differenze significative in ambito di illuminazione, risoluzione e qualità delle immagini. Questo può rendere difficile per il modello riconoscere le caratteristiche cromatiche;
- soggettività del topic → oltre ad essere uno studio recente e inedito soprattutto, l'armocromia è un argomento estremamente dettagliato. Infatti, le differenze tra le diverse classi cromatiche sono sottili e facilmente confondibili.

Tutte queste problematiche, in particolare la diversità delle caratteristiche visive delle immagini all'interno della stessa classe e la quantità limitata di immagini disponibili per ciascuna classe, hanno impedito di ottenere una buona performance con le 12 classi. Di seguito riportiamo due esempi per chiarire il concetto di diversità delle caratteristiche visive all'interno della stessa classe.

### *Summer soft*



## Autunno soft



Come si può notare, nel primo esempio di "Summer Soft", tutte e tre le immagini appartengono alla categoria "Summer Soft", ma presentano comunque caratteristiche differenti tra di loro, pur appartenendo alla stessa classe. Lo stesso accade nel secondo esempio, in cui tutte e tre le immagini sono classificate come "Autunno Soft", ma presentano comunque caratteristiche differenti pur facendo parte della stessa classe. Pertanto, questa diversità intrinseca all'interno della stessa categoria può rendere complesso per il nostro modello identificare e classificare le immagini, soprattutto se la quantità di immagini disponibili è limitata.

Pertanto, nel tentativo di migliorare la performance del nostro modello, abbiamo

ridotto le 12 classi a 4 macro-classi (AUTUNNO, ESTATE, INVERNO, PRIMAVERA). La riduzione del numero di classi ha portato a un significativo miglioramento delle prestazioni del modello: la percentuale di accuratezza è raddoppiata, raggiungendo il 61,1%. Come evidenziato dalla matrice di confusione, il modello di classificazione ha correttamente predetto 471 delle 771 immagini del set di Test. Ridurre le classi da 12 a 4 ha permesso di aumentare il numero di immagini per ciascuna classe, consentendo al modello di cogliere meglio le caratteristiche distintive di ogni classe. Inoltre, la minore diversità delle immagini all'interno di ciascuna classe ha contribuito a un maggiore equilibrio tra le classi, migliorando ulteriormente le prestazioni del modello.


		Predicted				
		AUTUNNO	ESTATE	INVERNO	PRIMAVERA	$\Sigma$
Actual	AUTUNNO	86	24	34	37	181
	ESTATE	17	157	16	26	216
	INVERNO	26	14	141	20	201
	PRIMAVERA	28	29	29	87	173
$\Sigma$		157	224	220	170	771

TEST		CA	IMMAGINI	EMBEDDER
AUTUNNO, INVERNO, ESTATE, PRIMAVERA	61.1%	771		SqueezeNet


Evaluation results for target (None, show average over classes) ▾						
Model	AUC	CA	F1	Prec	Recall	MCC
Neural Network	0.804	0.611	0.608	0.607	0.611	0.480

Nonostante la riduzione delle classi a 4 abbia migliorato le performance del modello, su un totale di 771 immagini del set di Test, 300 sono

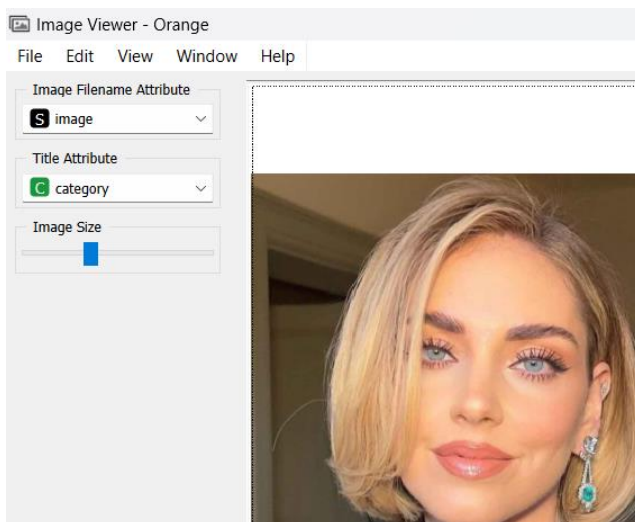
state classificate erroneamente. Di seguito sono riportati alcuni esempi di *misclassificazioni*.




*AUTUNNO* misclassificata in *ESTATE*.



*ESTATE* misclassificata in *AUTUNNO*



*PRIMAVERA* misclassificata in *ESTATE*



*AUTUNNO* misclassificata in *PRIMAVERA*



## Tabelle riepilogative

	CLASSI	CA	EMBEDDER
TENTATIVO N.1	12	23.7%	SqueezeNet
TENTATIVO N.2	12	29.2%	SqueezeNet
TENTATIVO N.3	4	61.1%	SqueezeNet

Nonostante la rete neurale convoluzionale (CNN) più adatta per il nostro compito sarebbe dovuta essere la pre-allenata *OpenFace*, a fornire la migliore percentuale di accuratezza in tutti e tre i tentativi svolti è stata *SqueezeNet*.

Tuttavia, al fine di comprendere quale fosse la rete che ci consentiva la migliore performance, abbiamo provato diverse reti disponibili. Di seguito sono riportati i risultati ottenuti con le varie CNN nei tre tentativi effettuati

	SQUEEZENET	OPENFACE	INCEPTION V3	DEEPL0C	PAINTERS
TENTATIVO N.1	23.7%	22.8%	20.6%	18.1%	23.4%
TENTATIVO N.2	29.2%	27.5%	25%	19%	25.8%
TENTATIVO N.3	61.1%	46.1%	47.6%	39.8%	47.9%

## CONCLUSIONI

Nonostante la riduzione delle classi da 12 a 4 abbia portato ad un miglioramento della prestazione del modello di catalogazione, con un'accuracy del 61.1%, questo dato non è ancora da ritenersi pienamente soddisfacente. Per aumentare ulteriormente l'accuratezza del modello, ci sono alcune strategie da mettere in atto: sicuramente prima tra tutte aumentare il numero di immagini che compongono il dataset. È necessario disporre di un ampio e diversificato set di dati per addestrare il modello, più dati di addestramento si hanno, meglio il modello può imparare a generalizzare e a cogliere le variazioni nelle caratteristiche dei dati. Inoltre, è fondamentale bilanciare

correttamente le classi, cioè assicurarsi che ogni classe abbia un numero simile di immagini. Questo è importante perché lo squilibrio potrebbe portare il modello a concentrarsi maggiormente sulla classe dominante, trascurando le classi meno rappresentate e riducendo quindi le prestazioni del modello su di esse. Anche l'annotazione deve essere effettuata nella maniera più coerente possibile. Le immagini che compongono il dataset devono essere di qualità e risoluzione alte.

